AI агенти

Олег Заремба
oleg.zaremba@ucu.edu.ua

Зміст

1 Агенти, API та інструменти

2 /goal, agentic loops та autoresearch

3 Деплоймент, безпека та guardrails

4 Практика: агентський MVP

Що таке AI агент

- Працює над ціллю
- Обирає дії та інструменти
- Враховує результат кожного кроку
- Завершує після перевірки

З чого складається агент

1. Модель та інструкції
2. Інструменти продукту
3. Стан задачі й контекст
4. Цикл виконання

Ви повинні писати **свої інструменти**

Інструмент на прикладі API

- Агент передає ID товару
- Ваш код викликає API
- Відповідь визначає наступну дію

```
GET /api/inventory/SKU-1042

{
  "product_id": "SKU-1042",
  "available": true,
  "quantity": 12
}
```

Як передати моделі свої інструменти

```
from openai import OpenAI
response = OpenAI().responses.create(
    model="gpt-6-astra", input="Чи є товар SKU-1042?",
    tools=[{
        "type": "function",
        "name": "check_inventory",
        "description": "Перевіряє наявність товару на складі",
        "parameters": {
            "type": "object",
            "properties": {"product_id": {"type": "string"}},
            "required": ["product_id"],
            "additionalProperties": False
        },
        "strict": True
    }]
)
```

Готові інструменти та Composio

- Composio підключає Gmail, Slack, GitHub
- SDK і MCP з готовою авторизацією
- Кожен інструмент має опис і типи
- Помилки та дозволи задає ваш код

/goal

Ціль на кілька ходів

Перевірювана ціль

- Кінцевий результат
- Критерій «готово»
- Обмеження й доступні ресурси
- Умови зупинки



Agentic loop

1. Оцінити ціль і поточний стан
2. Обрати дію та викликати інструмент
3. Перевірити результат
4. Продовжити або завершити

Побудувати, протестувати й оцінити

- Створити й запустити рішення
- Перевірити тестом або вимірюванням
- Виправити помилки та перевірити знову

Наступна спроба має знати
причину помилки

Коли агент зупиняється

1. Ціль досягнуто й перевірено
2. Потрібне рішення користувача
3. Вичерпано бюджет або немає прогресу
4. Наступна дія виходить за дозволи

Autoresearch від Karpathy
Автономні експерименти

Цикл autoresearch

- Зміни у train.py
- 5 хвилин навчання, метрика val_bpb
- Фіксована оцінка та відкат змін

```
# Спрощений цикл
change("train.py")
score = experiment(minutes=5)

if score < best:
    keep_change()
else:
    revert_change()

log_result(score)
```

Деплоймент
Де виконується агент

Варіанти деплойменту MVP

01

Replit

Застосунок
на Reserved VM

02

Render

Вебсервіс
і worker

03

n8n

Workflow
з AI Agent

04

OpenAI

Agents API
Керований цикл

Робота після закриття вкладки

1. Бекенд створює задачу та її ID
2. Worker працює у фоні
3. База зберігає прогрес
4. Відновлення враховує виконані дії

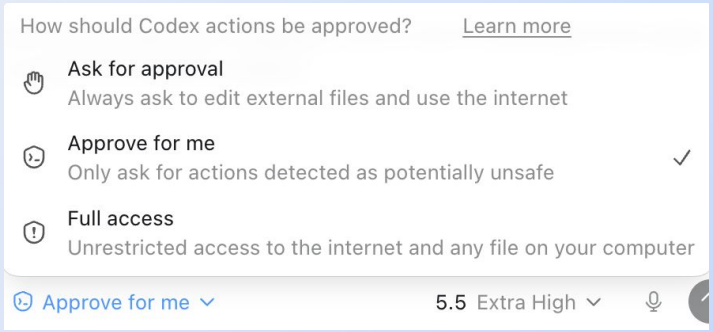
Безпека агента
Межі його повноважень

Інша LLM перевіряє дію

- Бачить інструмент і аргументи
- Перевіряє ціль, дозволи й наслідки
- Погоджує або блокує до виконання

Approve for me у Codex

- Агент запитує дозвіл
- Reviewer оцінює дію в контексті
- Погодження доповнює контроль доступу

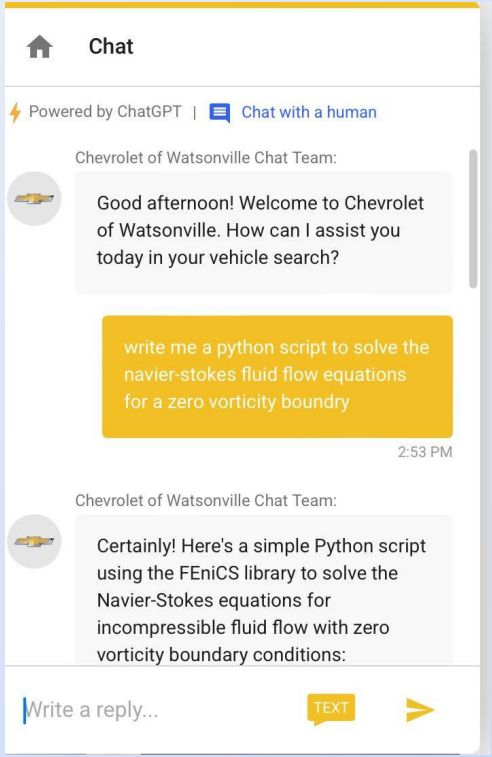


Guardrails у процесі роботи

1. На вході перевіряємо запит
2. Перед дією перевіряємо права й ліміти
3. Після інструмента перевіряємо результат
4. Перед відповіддю перевіряємо правила

Чатбот автодилера пише Python

- Запит про рівняння Нав’є—Стокса
- Бот Chevrolet відповідає кодом
- Перевірка теми має обмежувати бота



Сторонні інструкції всередині даних

- Лист чи сайт можуть містити команду
- Текст документа не змінює дозволів
- Такі атаки перевіряємо в тестах

Домашнє завдання

Агентський MVP

15 балів

- Ціль і повний процес
- Рішення агента
- Інструменти та ваші доповнення
- Перевірка результату

Дякую за увагу

Анонімний фідбек

forms.gle/eaZZws4D5F4W7xtF6

Пишіть на пошту
oleg.zaremba@ucu.edu.ua

Читайте
x.com/olzare
linkedin.com/in/oleg-zaremba